智能能力网络的能力协作与信任机制

授权衰减 契约组合与结果证据的形式化研究

English · 中文入口

摘要

能力可以被发现，不代表调用者有权使用；动作被接受，不代表目标已经实现。智能能力网络的协作问题因此需要同时处理行为契约、授权范围、时效和结果证据。本文提出按证明义务组织协作过程：每项候选能力承担兼容性、执行许可、状态有效性和目标实现等不同义务，结果声明仅覆盖已经得到支持的部分。

本文给出授权沿委托路径衰减的集合模型，证明复合任务所需权限应按动作需求合并、再逐项受到上级授权约束；建立关系契约的顺序组合与并发非干扰条件；推导撤销传播、凭据寿命和已接受动作延迟共同决定的陈旧授权窗口；并用不可区分执行说明分区期间即时撤销与完全授权可用性的冲突。对于结果验证，本文区分观察真实性与目标真实性，给出验证器相关时的保守误判界，以及证据失效对依赖结论的传播规则。

本文的研究设想是让能力协作携带尚未完成的证明义务，并把发现覆盖证据与执行结果证据连接起来。契约逻辑、最小权限、授权衰减与概率推理已有成熟基础；本文不把这些基础方法改名为新定理，也不把框架的合理性当作经过实验验证的效果。

关键词：智能能力网络；能力契约；授权衰减；协作正确性；撤销时效；结果证据

1 从能力发现到可负责的协作

本文的 ICN 指 Intelligent Capability Network，即智能能力网络。能力是主体在指定条件下可以完成某类状态转换的契约，而不是一句功能描述或一个端点地址。网络可以包含软件服务、模型、传感设备和能够改变物理环境的执行者；一个管理域对其对外声明及授权边界负责。

协作包含发起者、能力拥有者、发现者、执行者和结果验证者等角色。同一个实体可以承担多个角色，但角色合并不能消除其证明义务。例如，发现者找到“测量温度”的服务，并不因此成为温度测量的可信来源；代理能代表用户查找服务，也不因此能代表用户开启设备。

配套论文《策略约束下的递归能力发现》研究候选声明集合的覆盖、预算与一致性。本文从候选已被返回开始，考察“可以替换什么能力”“谁允许什么动作”“何时许可仍有效”和“什么证据支持目标已实现”。两篇论文共同采用显式参考范围，避免把局部结论扩展为全系统保证。

MCP 和 A2A 的官方规范为工具与智能体交互提供接口语义 [1–2]；它们的存在不自动证明任何业务目标得到实现。NIST 零信任架构提供按资源和请求评估访问的背景 [3]。行为子类型、Hoare 逻辑和带约束的委托凭据分别为契约、组合和权限衰减提供既有理论基础 [4–6]。本文的增量研究对象是这些条件如何在同一个跨域任务中保持一致，以及证据不足时应怎样限定结果声明。

2 能力模型与证明义务

2.1 状态关系与动作权限

令 S 为相关世界状态集合，$\mathcal{A}$ 为带有资源、主体、动作、目的和时间上下文的具体动作集合。能力 c 的行为规格为

$$K_c = (P_c, R_c, Q_c, E_c), \qquad R_c \subseteq S \times S. \qquad (C1)$$

P_c 是前置状态集合，R_c 描述允许的状态转换，Q_c 是后置状态集合，$E_c \subseteq \mathcal{A}$ 为允许的动作或副作用。输入、输出和环境观测可以并入状态；这样不会用一个输出字段掩盖未声明的物理作用。对前置条件内所有实际发生的转换，部分正确性要求

$$R_c(P_c) \subseteq Q_c, \qquad \mathrm{Effects}(c) \subseteq E_c. \qquad (C2)$$

$R_c(P_c)$ 表示从 P_c 中状态可到达的后继集合。C2 不证明执行终止或截止时间；可能永不完成的能力也可满足部分正确性。若任务要求终止，需另加全正确性或有界完成的证明义务。

2.2 四种义务而非一个信任分数

对能力使用请求 x，定义类型兼容义务 O_T、授权义务 O_A、状态及时效义务 O_F 和目标证据义务 O_G。它们具有不同前提和证据来源。本文将义务状态记为已支持、已反驳、未决，不用一个加权信任分数把缺失的权限抵消掉。

发现阶段最多支持某些契约匹配；动作提交前必须支持 O_A 与所需的 O_F；完成声明必须支持对应的 O_G。这一阶段划分是研究框架的语义约束。它不会因为记录中写着“已支持”就成立：证据本身必须满足各节列出的可验证条件。

2.3 共同假设

所有命题都针对明确的动作范围与参考状态。用于授权的动作谓词可判定，权威主体身份与权限来源可验证，关键效应不能绕过模型中的授权判定。提供者是否真实遵守关系契约是外部证明或验证义务，不能仅凭自述成立。涉及物理效果时，状态模型必须说明可观察性、测量误差与环境干扰；若缺少这些条件，结论应退化为关于声明或观测的结论。

3 委托权限的衰减与组合

3.1 单条委托路径

固定判定时刻和完整上下文。令 $A_0 \subseteq \mathcal{A}$ 为根授权，$P_j \subseteq \mathcal{A}$ 为第 j 次委托附加的约束。子委托允许动作集合为

$$A_j = A_{j-1} \cap P_j, \qquad A_n = A_0 \cap \bigcap_{j=1}^{n} P_j. \qquad (C3)$$

命题 T1。 在约束不能被删除或替换、根授权有效且所有层在同一上下文中判定的条件下，任何层的授权都不超出其祖先授权。

证明。 集合交满足 $A_{j-1} \cap P_j \subseteq A_{j-1}$。逐层归纳得到 $A_n \subseteq A_{n-1} \subseteq \cdots \subseteq A_0$。Macaroons 的约束式委托体现了这种既有衰减思想 [6]；C3 是集合语义，不是新的密码学安全证明。

边界。 不同时刻重新计算的授权集合可能扩大或缩小，C3 的链式包含仅比较同一时刻和上下文。将“家庭内读取温度”转换成不含资源范围的“读取权限”，会丢失约束，破坏模型。委托链中签名完整也不能修复错误的上下文映射。

3.2 多个根授权与权限拼接

主体可能从不同拥有者取得独立授权。若策略允许替代授权来源，一个具体动作只需落入其中一条有效授权链；但不能把一张凭据中的资源字段与另一张凭据中的动作字段任意拼接。每张授权描述的是完整动作元组的集合，而不是可随意组合的字段列表。

例如，凭据甲允许对资源甲执行读取，凭据乙允许对资源乙执行写入；两者的集合并允许这两个完整动作，不允许对资源甲执行写入。该反例说明，将多个字段分别取并集再做笛卡尔积，会产生原授权中没有的动作。

3.3 复合任务需要的是权限需求的并集

设任务 T 包含动作需求集合 $N_1, \ldots, N_k$。在同一根授权下，能够完成全部子任务的必要授权条件是

$$N_T = \bigcup_{i=1}^{k} N_i \subseteq A_0, \qquad N_i \subseteq A_i \subseteq A_0. \qquad (C4)$$

命题 T2。 若每个子任务仅使用其授权集合 A_i 中的动作，且 C4 成立，则组合不引入根授权以外的动作。

证明。 任取组合发生的动作。它来自某个子任务，属于该子任务的 A_i，而 $A_i \subseteq A_0$，故属于根授权。这个结论只证明权限不越界，不证明任务能够完成。

权限需求应取并集，委托限制应取交集，这是两个不同层次。把所有子任务的权限取交集可能误判一个合法任务无法完成；把不同根的委托条件无约束取并集又可能放大权限。多根任务需逐动作提供一条完整有效的授权路径，并处理明确要求共同批准的策略；“存在一个授权者”不能覆盖要求多方同意的规则。

4 行为契约的替换与组合

4.1 替换关系必须约束行为

令旧能力为 o，替代能力为 n。为了使依赖旧规格的调用方保留其安全性质，充分条件是

$$P_o \subseteq P_n, \qquad R_n(s) \subseteq R_o(s)\ (s \in P_o), \qquad E_n \subseteq E_o. \qquad (C5)$$

命题 T3。 若真实执行遵守规格且 C5 成立，则替换能力在旧合法前置状态上，不产生旧规格禁止的后继状态或额外作用。

证明。 任取 $s \in P_O$，第一条件保证新能力接受其前置状态。任取新能力产生的后继 s'，由第二条件有 $s' \in R_O(s)$。第三条件约束其作用。因此任何对旧关系全部允许后继成立的安全断言，也对新能力的后继成立。

这采用行为精化与子类型的既有思想 [4]。仅比较输出类型不足以证明 C5：两个能力都返回“成功”，其中一个额外开启门锁，就可能满足相同输出结构却违反作用约束。C5 仍不保证新能力终止，不保证概率分布、耗时或资源消耗相同；这些属性必须进入规格后才能讨论保留。

4.2 顺序组合

考虑能力 c_1, c_2。若它们满足部分正确性，且 $Q_1 \subseteq P_2$，则

$$R_1(P_1) \subseteq Q_1 \subseteq P_2, \qquad (R_2 \circ R_1)(P_1) \subseteq Q_2. \qquad (C6)$$

证明。 从任意 P_1 状态执行第一能力，若终止，其后继在 Q_1 内，因而满足第二能力的前置条件。第二能力若终止，其后继在 Q_2 内。这里使用的是 Hoare 风格的顺序组合规则 [5]。若两能力之间有环境转换 R_e，连接条件必须改为 $R_e(Q_1) \subseteq P_2$，不能忽略间隔中的状态变化。

依赖图无环只给出一个执行偏序，不证明任何 $Q_i \subseteq P_j$。例如“已经取得温度读数”不能推出“读数仍在控制精度和有效时间范围内”。需要显式的误差及有效期条件，才能把观测接到控制动作。

4.3 并发的非干扰条件

设能力 i 的读状态分量集合为 $\mathcal{R}_i$，写状态分量集合为 $\mathcal{W}_i$。在状态为这些分量的积空间、转换只依赖所声明读分量且只修改所声明写分量、没有隐含共享资源或外部干扰的模型中，以下条件足以支持两个动作交换次序：

$$\mathcal{W}_i \cap (\mathcal{R}_j \cup \mathcal{W}_j) = \varnothing, \qquad \mathcal{W}_j \cap (\mathcal{R}_i \cup \mathcal{W}_i) = \varnothing. \qquad (C7)$$

证明要点。 任一动作不改变另一动作所读取或写入的分量，因此第二个动作看到的相关输入不变，两个动作产生的写入也互不覆盖；可达后继关系在该积状态模型中交换。若偏序中所有无依赖动作对均满足这一条件，任意两个拓扑序可通过交换相邻无依赖动作互相转换，从而保持相同的关系语义。

这不是说现实设备只要名称不同就无干扰。加热器和空调共享室温这一状态变量，两个机器人可能共享通道；遗漏这些分量会使 C7 的表面检查失去意义。单纯的任务图结构也不提供原子性或补偿能力，已经发生的物理作用一般不能由一个“撤回”声明逆转。

5 撤销与时间有效性

5.1 授权检查与动作提交之间的间隔

设权威方在真实时间 t_r 撤销授权。撤销信息在至多 d 时间内到达相关判定者；凭据最长寿命为 L；签发者和判定者时钟与真实时间的误差绝对值均不超过 ϵ。已经通过授权接受的动作至多在 Δ 后提交副作用。假定撤销后不再签发该授权的新凭据，凭据不能延长寿命，并且失效或已获知撤销的凭据不再被接受。

命题 T4。 在这些条件下，撤销后仍可能发生的旧授权提交，其时间窗口满足

$$W \le \min\{d, L + 2\epsilon\} + \Delta. \qquad (C8)$$

证明。 撤销传播使最后一次接受旧授权不晚于 $t_r + d$。任何撤销前签发的凭据在真实时间上的最晚可接受期限不晚于 $t_r + L + 2\epsilon$，其中两倍时钟误差来自签发时钟偏快和判定时钟偏慢的组合。两个停止接受条件任一生效即可，因此最后接受时间受较小者限制。已经接受的动作仍可能延迟 Δ 提交，得到 C8。

若提交时重新检查有效期，界可以进一步收紧；若动作接受后无有限提交延迟，则 C8 无有限上界。分区使 d 无界时，凭据寿命仍可限制新接受，但依赖可信时钟和不续发的前提。若只撤销目录记录而不撤销动作权限，C8 的授权前提根本没有建立。

例如 $d = 5$ 秒、$L = 30$ 秒、$\epsilon = 0.1$ 秒、$\Delta = 0.5$ 秒，则界为 5.5 秒；分区时以寿命约束计算为 30.7 秒。这是给定参数的上界算例，不是测得的撤销延迟。

5.2 即时撤销与分区可用性的冲突

命题 T5。 在权威方与执行者可以无限期失联的模型中，若执行者没有能区分远端是否撤销的新信息，就不能同时保证“撤销后不再提交任何新动作”和“未撤销时每个合法请求在分区期间仍能成功执行”。

证明。 构造两个在执行者处具有相同历史的世界。世界一在分区后远端撤销授权，世界二不撤销。令同一个动作请求在撤销时刻之后到达执行者。因为执行者观察不到远端事件，两世界具有相同的决定或相同的随机决定分布。若它保证在世界二执行，则也会在世界一执行，违反即时撤销；若为世界一的安全而拒绝或永久等待，则世界二不能满足完全授权可用性。证毕。

这个局部不可区分证明与经典分区一致性论证相关 [7]，但本文的“可用性”特指合法动作成功执行，不是仅返回错误响应。即时撤销若要成立，需要将撤销与动作提交纳入同一可比较、不可绕过的权威顺序，或在无法取证时停止接受。版本号递增只证明已知历史不回退，不能证明执行者已经知道最新撤销。

6 从观测证据到目标声明

6.1 签名与真实性的层次

消息签名能够支持特定消息成分的来源和完整性判定 [8]。若提供者签名声明“任务完成”，验证签名只说明该声明的来源与内容受到保护；提供者误判、传感器偏差或目标定义错误都仍可能存在。因此必须分开：消息由谁产生、记录是否被修改、测量是否可靠、目标是否真正实现。

设 G 为目标实际上成立，V 为验证器给出通过。令先验 $\pi = \Pr(G)$、检出率 $s = \Pr(V \mid G)$、误通过率 $f = \Pr(V \mid \neg G)$。在分母为正时，贝叶斯公式给出

$$\Pr(G \mid V) = \frac{s\pi}{s\pi + f(1-\pi)}. \qquad (C9)$$

例如 $\pi = 0.1, s = 0.95, f = 0.05$，通过后的目标真实概率约为 0.679，而非 0.95。公式是经典概率恒等式；这里的作用是指出验证器准确性、任务基准概率与“通过后可信度”不能互相替代。没有这些参数的可靠估计时，应报告未校准的证据，不能编造一个信任概率。

6.2 多验证器之间的相关性

设目标为假时两个验证器的误通过率分别至多 α_1, α_2。无需独立假设即可得到

$$\Pr(V_1 \cap V_2 \mid \neg G) \le \min\{\alpha_1, \alpha_2\}. \qquad (C10)$$

只有在给定目标为假及相关上下文后仍条件独立，才可用概率乘积。两个验证器复制同一个错误传感器的读数时，误判可以完全相关：各为 0.05，联合仍为 0.05，而非 0.0025。增加验证器数量不等于增加独立证据；需要追踪共同数据源、模型来源和失效原因。

6.3 多目标任务的保守声明

设复合目标为 $G = \bigcap_i G_i$，全体已接受证据为 $\mathcal{E}$。若对每个子目标已有在同一完整证据条件下校准的失效上界 $\Pr(\neg G_i \mid \mathcal{E}) \le \delta_i$，则

$$\Pr(G \mid \mathcal{E}) \ge \max\left\{0, 1 - \sum_i \delta_i\right\}. \qquad (C11)$$

证明。 $\neg G$ 是子目标失效事件的并集，对同一条件概率空间应用并集界即可。该界不需要子目标独立，但通常较保守。仅有各自局部证据下的失效率，不能直接作为完整联合证据条件下的 δ_i；额外证据可能改变相关性和后验分布。

若某子目标缺乏上界，只能以 1 作为其最坏失效上界，整个合取目标的概率保证可能退化为 0。此时应保留已经得到支持的子目标声明，同时将整体目标标为未决，而不是对各子目标可信度取平均后宣告成功。

7 证据依赖与未决义务

7.1 依赖图与结论失效

将证据与结论组织为有向无环图 $G_E = (N_E, E_E)$，边从前提指向依赖它的结论。叶证据必须有明确来源、时间、作用域和接受条件。一个推导节点要求其列出的全部前提及推导规则都有效；替代证明路径应分别表示，不能混成一个含义不清的前提列表。

若节点 z 的证据失效，令 $\mathrm{Desc}(z)$ 为沿依赖边可达的结论集合。其支持状态至少需要重新评估的范围为

$$\mathcal{I}(z) = \{z\} \cup \mathrm{Desc}(z). \qquad (C12)$$

命题 T6。 在每个结论仅依赖图中列明前提、且所有前提是合取支持的条件下，失效只需沿后继传播即可找到全部失去该证明支持的结论；不在可达集合中的结论不因这项前提变化而失去其图内支持。

证明。 依拓扑序归纳。直接依赖 z 的结论首先失去一个必要前提；其后继继而失去必要支持。所有沿路径可达节点都如此传播。不可达节点的前提传递闭包不含 z，其支持检查不涉及该节点。存在其他独立证明时，结论可以重新取得支持。失去证明不等于实际命题变假，因而应退回未决而非自动判为失败。

该规则的前提是依赖记录完整。隐藏的共享传感器、同源模型错误或遗漏的授权依赖，会让图低估传播范围。循环自我背书也不能形成独立证据；无外部可信基础的环不能通过重复引用使结论成立。

7.2 从发现覆盖到任务义务前沿

配套 RCAP 论文将尚未搜索的区域表示为未决前沿。本文提出相应的任务义务前沿：在任务依赖图上，记录尚无有效支持的必要条件。前沿可能包含未验证的能力契约、已过期的许可、未完成动作和尚未确认的目标状态。一个任务的结果声明应由已支持子图导出，不应覆盖仍依赖未决前沿的目标。

两类前沿不能直接等同。发现论文的计数上界可给出候选召回下界；任务中的一个关键安全条件未决，可能阻止整个任务，即使其余 99 个条件已经满足。因此“99% 义务完成”一般不等于“99% 成功概率”。只有给定概率模型和 C11 的校准条件后，才能作概率化陈述。

7.3 一个贯穿的协作例子

考虑目标“确认房间无人后，将温度调到指定区间并确认结果”。发现阶段找到占用检测、温度测量和温控三个候选。检测记录必须满足有效期；温控权限必须覆盖该房间、动作范围和使用时段；温度观测应包含误差界。若读数为 y、绝对误差至多 η，要保证真实温度在 $[l, u]$ 内，充分条件为

$$[y - \eta, y + \eta] \subseteq [l, u]. \qquad (C13)$$

例如目标区间为 20 至 24 度，读数 23.8 度、误差界 0.5 度时，不能据此确认目标成立；读数 22 度、相同误差界则满足该测量时刻的条件。若还要保证之后十分钟持续满足目标，必须加入环境变

化界与后续控制条件，单次测量无法完成证明。

检测无人之后可能有人进入，因而顺序组合必须处理环境关系 R_e；“检测完成”本身不保持温控动作的前置条件。若占用检测后来被发现失效，依赖它的安全许可应重新评估，但已完成的温度测量并不因此成为假数据。这个例子把授权、时效、行为与结果证据放在同一因果结构中，也显示了它们不能互相替代。

8 研究贡献与可反驳条件

本文的拟议贡献是将权限路径、关系契约和证据依赖共同绑定到具体任务义务，形成可局部支持、可局部失效、可以保留未决状态的结果语义。它不是一种通用信任评分，也不是对所有智能体的自动正确性证明。已有工作分别提供了主要逻辑工具 [3–8]；框架是否带来额外研究价值，取决于以下问题。

候选主张	可检验内容	明确的失败情况
权限路径约束能够阻止协作放大授权	对每个实际动作追溯完整授权元组	任一动作仅靠跨凭据拼接字段获得许可
关系契约比输出类型更能约束替换	检查后继状态与作用包含关系	输出合格但出现旧契约禁止的作用
撤销窗口可由时效参数约束	在 C8 全部前提内比较最晚提交时刻	提交越界却无法指出被破坏的假设
依赖图支持局部结论更新	比较完整依赖闭包与受影响声明	存在隐藏前提导致必要更新遗漏
未决义务减少无依据的整体成功声明	对照只使用统一成功状态的语义	仍有必要目标未决却输出整体已验证

后续研究需要处理谓词表达能力与可判定性的冲突、跨域证据最小披露、物理状态抽象的误差、可信根被攻破以及概率校准随任务分布变化而失效等问题。本文没有完成模型检查、经验比较或普遍的新颖性证明。上述命题已经给出条件化论证；更强的能力需要更强的前提或新的证据，而非进一步扩大措辞。

9 结论

智能能力协作的可信性来自可追溯的权限、可组合的行为规格、明确的时间条件和与目标对应的证据。委托路径上的交集约束限制权限增长，任务动作需求的并集表达真实授权需求，关系契约解释替换和组合，证据依赖则决定哪些结论在前提变化后仍可保留。将未决义务显式留在结果中，使局部成功和整体未完成能够同时被准确表达。

参考文献与核验说明

核验日期为 2026 年 10 月 28 日。以下来源均通过官方发布页、作者机构页面或论文原文确认存在；各条后的用途说明限定其支持范围。持续更新的规范记录访问日期，经典文献不被用作本文联合框架的原创性证明。

[1] Model Context Protocol. Specification, 2026-07-28. 官方版本. 工具交互背景。

[2] A2A Project. Agent2Agent Protocol Specification. 官方规范. 持续更新页面，访问日期 2026-10-28；替换原稿依赖仓库内部路径的链接。

[3] Rose, S.; Borchert, O.; Mitchell, S.; Connelly, S. Zero Trust Architecture. NIST SP 800-207, 2020. NIST 官方页面. 访问控制原则背景，不是物理目标正确性的证明。

[4] Liskov, B. H.; Wing, J. M. A Behavioral Notion of Subtyping. ACM Transactions on Programming Languages and Systems, 16(6), 1994, 1811–1841. DOI: 10.1145/197320.197383. 作者机构论文. 行为替换的理论基础。

[5] Hoare, C. A. R. An Axiomatic Basis for Computer Programming. Communications of the ACM, 12(10), 1969, 576–580, 583. 牛津大学作者文献目录. 顺序组合与部分正确性的理论基础；题名、年份和页码由作者机构目录核验。

[6] Birgisson, A.; Politz, J. G.; Erlingsson, Ú.; Taly, A.; Vrable, M.; Lentczner, M. Macaroons: Cookies with Contextual Caveats for Decentralized Authorization in the Cloud. NDSS, 2014. 会议官方页面. 约束式委托背景。

[7] Gilbert, S.; Lynch, N. Brewer's Conjecture and the Feasibility of Consistent, Available, Partition-Tolerant Web Services. SIGACT News, 33(2), 2002. DOI: 10.1145/564585.564601. 作者机构论文. 分区与不可区分执行的相关理论。

[8] Backman, A.; Richer, J.; Sporny, M. HTTP Message Signatures. RFC 9421, 2024. RFC Editor. 消息来源和完整性机制的规范基础，不支持把签名当作现实效果证明。

原稿中的 OpenTelemetry 与通用传输说明不再用于支撑信任论证；相关引用已移除。服务发现的规范背景集中在配套 RCAP 论文中，本篇不再重复罗列。